Iniciado em	sexta-feira, 18 set. 2026, 19:04
Estado	Finalizada
Concluída em	sexta-feira, 18 set. 2026, 19:07
Tempo empregado	3 minutos 20 segundos
Avaliar	**4,25** de um máximo de 10,00(**42,5**%)
Comentários	**Sua tentativa foi registrada.**

Nas **questões 4 a 9**, a correção automática indica apenas o acerto da alternativa. A pontuação permanece **provisória até a conferência do notebook**, considerando os códigos, resultados, gráficos solicitados e justificativas.

A alternativa correta sem validação adequada no notebook receberá zero no respectivo item. As questões 1, 2, 3 e 10 dispensam essa validação.

A nota definitiva será disponibilizada após a conferência docente.

Informação

AT1 - Instruções, fórmulas e métodos

- Avaliação individual com dez questões objetivas e uma entrega de notebook. Marque uma alternativa por questão.
- Duração total: **100 minutos**. Reserve os dez minutos finais para revisão e envio.
- As questões **4, 5, 6, 7, 8 e 9** exigem código executado, saídas e justificativa no notebook. Os gráficos solicitados integram essa validação. Acerto sem validação adequada recebe zero no item.
- As questões 1, 2, 3 e 10 dispensam Colab e valem 0,5 ponto cada. As questões 4 e 6 valem 1 ponto cada. As questões 5, 7, 8 e 9 valem 1,5 ponto cada. Total: **10 pontos**. O envio do notebook não tem pontuação separada.
- Utilize o notebook modelo e os CSVs desta prova. Mantenha os nomes dos arquivos. Não envie somente um link do Colab.
- Não se comunique com outros alunos durante a avaliação. Utilize apenas os recursos autorizados pelo docente.
- Você pode retornar a esta página para consultar fórmulas e métodos durante a resolução.

Baixar pacote de recursos (notebook modelo e CSVs)

Abrir Google Colab (nova janela)

Fórmulas de consulta

Extraídas dos notebooks das aulas 6, 7, 8 e 9. Use a convenção amostral para variância e desvio-padrão.

Frequência relativa e percentual

$$h_j = \frac{f_j}{n} \qquad p_j = 100 h_j$$

Média aritmética

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i .$$

Mediana

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & n \text{ ímpar}, \\ \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & n \text{ par}. \end{cases}$$

Amplitude total

$$R = x_{(n)} - x_{(1)} .$$

Variância amostral

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 .$$

Desvio-padrão amostral

$$s = \sqrt{s^2} .$$

Quartis por interpolação linear

$$I(h) = \begin{cases} x_{(1)}, & h \le 1, \\ (1-d)x_{(i)} + d x_{(i+1)}, & 1 < h < n, \\ x_{(n)}, & h \ge n. \end{cases}$$

$$p = \frac{j}{m}.$$

$$H_p = 1 + (n-1)p, \qquad q_p = I(H_p).$$

Intervalo interquartil

$$\mathrm{IQR} = Q_3 - Q_1 = q_{0,75} - q_{0,25} .$$

Cercas de Tukey

$$L = Q_1 - 1{,}5\,\mathrm{IQR}, \qquad U = Q_3 + 1{,}5\,\mathrm{IQR}.$$

Ponto médio de classe

$$m_j = \frac{L_j + U_j}{2}.$$

Média agrupada

$$\bar{x}_g \approx \frac{\sum_{j=1}^{k} f_j m_j}{\sum_{j=1}^{k} f_j} = \frac{\sum_{j=1}^{k} f_j m_j}{n}.$$

Variância agrupada amostral

$$s_g^2 \approx \frac{\sum_{j=1}^{k} f_j (m_j - \bar{x}_g)^2}{n-1}.$$

Desvio-padrão agrupado

$$s_g \approx \sqrt{s_g^2}.$$

Classe modal

$$\square_{\text{modal}} = \left\{ j : f_j = \max_{1 \le r \le k} f_r \right\}.$$

Percentual conjunto

$$100\frac{n_{ij}}{n}.$$

Percentuais condicionais

Por linha: $100 n_{ij}/n_{i\cdot}$. Por coluna: $100 n_{ij}/n_{\cdot j}$.

O denominador é o total do grupo indicado e deve ser positivo. Fonte: aula 9, seção 5.1.

Notação

- n: número de observações. x_i: valor observado. $x_{(r)}$: valor na posição r da lista ordenada, com posições iniciadas em 1.
- Para os quartis, $p = j/4$, com $j = 1, 2, 3$. Na interpolação, $i = \lfloor H_p \rfloor$ e $d = H_p - i$.
- Q_1, Q_3: quartis. L, U: cercas de Tukey.
- L_j, U_j: limites da classe. m_j: ponto médio. f_j: frequência da classe. k: número de classes.
- n_{ij}: frequência da célula. $n_{i\cdot}$: total da linha. $n_{\cdot j}$: total da coluna.
- As medidas agrupadas são aproximações obtidas pelos pontos médios.

Bibliotecas, funções e métodos

Referência de sintaxe dos recursos usados nas soluções. Os nomes `coluna`, `valores`, `pesos`, `limites` e `condicao` são exemplos genéricos, a substituir pelos dados pertinentes.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

Recurso	Uso
`pd.read_csv("arquivo.csv")`	Ler um CSV com cabeçalho.
`pd.DataFrame({...})`	Organizar colunas em uma tabela.
`df["coluna"]` e `df[["coluna_a", "coluna_b"]]`	Selecionar uma ou mais colunas.
`df[condicao]`	Selecionar linhas por uma condição.
`df.loc[linha, "coluna"]`	Acessar ou atribuir um valor. Também aceita uma condição no lugar de `linha`.
`df["coluna"].mean()`	Calcular a média.
`df["coluna"].median()`	Calcular a mediana.
`df["coluna"].std(ddof=1)`	Calcular o desvio-padrão amostral.
`df.quantile([0.25, 0.50, 0.75])`	Calcular quartis das colunas numéricas. Interpolação linear por padrão.
`df["coluna"].quantile(0.25)`	Calcular um quantil de uma coluna.
`.sum()`, `.max()`, `.sort_values()`, `.round(casas)`	Somar, obter máximo, ordenar e arredondar valores.

Recurso	Uso
`np.arange(inicio, fim, passo)`	Gerar uma sequência, sem incluir `fim`.
`freq, limites = np.histogram(valores, bins=limites)`	Contar valores por classes. Limite direito incluído apenas na última classe.
`np.average(valores, weights=pesos)`	Calcular média ponderada.
`np.sum(valores)`, `np.sqrt(valor)`	Somatório e raiz quadrada.
`len(df)`, `round(valor, casas)`, `print(...)`	Número de linhas, arredondamento e exibição.
`plt.hist(valores, bins=limites, edgecolor="black")`	Construir histograma com classes definidas.
`plt.boxplot(valores)`	Construir um boxplot pelo critério de 1,5 IQR.
`plt.boxplot([grupo_a, grupo_b])`	Construir boxplots lado a lado.

Os métodos de resumo também podem ser aplicados às colunas numéricas de um DataFrame. Arredonde os resultados para apresentação, preservando a precisão nos cálculos intermediários.

Questão 1

Correto

Atingiu 0,50 de 0,50

Q1 (BARBETTA; REIS; BORNIA, 2010 p. 22) - População, amostra e alcance das conclusões

Uma universidade deseja conhecer o tempo médio de deslocamento até o campus dos 1.200 estudantes matriculados nos cursos presenciais naquele semestre. A equipe sorteia 120 estudantes a partir da lista completa de matrículas, sem reposição. Todos os selecionados respondem, e cada estudante fornece um registro do seu tempo de deslocamento.

O relatório apresenta duas afirmações:

I. Entre os 120 participantes, o tempo médio registrado foi de 42 minutos.

II. Com base nesses participantes, estima-se em 42 minutos o tempo médio dos 1.200 estudantes.

Qual afirmação identifica corretamente os elementos da investigação e o alcance das conclusões?

Validação no Colab

Dispensada. Questão conceitual sobre população, amostra, unidade de análise e distinção entre descrição e inferência.



A. A população é formada pelos 120 participantes, e a amostra reúne os 1.200 matriculados. Cada estudante é a unidade de análise. I descreve os registros, enquanto II estima uma característica da população.

B. A população reúne os 1.200 matriculados, e a amostra contém 120 participantes. O tempo em minutos é a unidade de análise. I descreve os registros, enquanto II estima uma característica da população.

C. A população reúne os 1.200 matriculados, e a amostra contém 120 participantes. Cada estudante é a unidade de análise. I faz uma inferência sobre os participantes, enquanto II apenas descreve os registros.

D. A população reúne os 1.200 matriculados, e a amostra contém 120 participantes. Cada estudante é a unidade de análise. I é descritiva, enquanto II é inferencial e envolve incerteza na generalização. ✓ identifica corretamente população, amostra e unidade de análise e distingue descrição dos dados observados de generalização com incerteza.

E. A população reúne os 1.200 matriculados, e a amostra contém 120 participantes. Cada estudante é a unidade de análise. I é descritiva, enquanto II estabelece a média populacional sem incerteza pelo sorteio.

Alternativa correta.

A alternativa D está correta. A população de interesse é delimitada pelos 1.200 estudantes matriculados nos cursos presenciais naquele semestre. A amostra é o subconjunto de 120 estudantes selecionados. Cada estudante é a unidade de análise e também a unidade observacional. O tempo de deslocamento é a variável, medida em minutos.

A afirmação I é descritiva porque resume os tempos registrados entre os participantes. Calcular uma média em uma amostra não torna essa conclusão automaticamente inferencial. A afirmação II é inferencial porque utiliza o resultado amostral para estimar uma característica dos 1.200 estudantes, incluindo aqueles que não foram observados.

O sorteio a partir da lista completa e a resposta de todos os selecionados favorecem a adequação da seleção ao objetivo. Ainda assim, outras amostras podem produzir médias diferentes. A média de 42 minutos é uma estimativa da média populacional, não uma igualdade garantida pelo sorteio. O levantamento também não é um censo, pois não observa os 1.200 estudantes.

A resposta correta é: A população reúne os 1.200 matriculados, e a amostra contém 120 participantes. Cada estudante é a unidade de análise. I é descritiva, enquanto II é inferencial e envolve incerteza na generalização.

Questão 2

Incorreto

Atingiu 0,00 de 0,50

Q2 (NAVIDI, 2024 p. 12) - Seleção da amostra e viés

Uma universidade deseja estimar a altura média de seus estudantes. A equipe responsável considera três estratégias de seleção:

I. Medir 50 estudantes encontrados no ginásio durante competições internas de basquetebol.

II. Medir todos os estudantes dos cursos de engenharia.

III. Medir os estudantes cujos nomes aparecem em primeiro lugar em cada página da lista telefônica da universidade.

Qual afirmação avalia corretamente a adequação dessas estratégias ao objetivo do levantamento?

Validação no Colab

Dispensada. Questão conceitual sobre seleção da amostra e representatividade.

A. A estratégia I é a mais adequada, pois reunir 50 estudantes em um espaço comum fornece diversidade suficiente para que o local de seleção não comprometa a estimativa da altura média da universidade.

B. A estratégia II é a mais adequada, pois medir todos os estudantes de engenharia elimina o viés de seleção e permite usar a média desse grupo para representar os estudantes dos demais cursos da universidade.

C. A estratégia III é a mais adequada entre as propostas, pois evita restringir a seleção ao ginásio ou à engenharia. A escolha do primeiro nome de cada página não garante representatividade nem aleatoriedade.

D. A estratégia III é a mais adequada, pois selecionar um nome por página constitui amostragem aleatória simples. A regularidade da regra garante a cada estudante a mesma chance de integrar a amostra selecionada. ✕ uma regra regular não equivale a uma seleção aleatória. Na lista fixa, apenas os nomes em primeiro lugar em cada página são escolhidos.

E. A estratégia mais adequada é a que reunir o maior número de estudantes, pois o aumento da amostra compensa as restrições de local, curso ou posição na lista e elimina o viés na estimativa da altura média.

Alternativa incorreta. Consulte a justificativa quando o feedback for liberado.

A alternativa C está correta. A estratégia III é a mais adequada entre as propostas porque não restringe diretamente a seleção aos frequentadores do ginásio ou a um conjunto de cursos. Ela pode alcançar estudantes de diferentes áreas, mas depende da cobertura e da organização da lista.

Selecionar o primeiro nome de cada página é uma regra determinística, não um sorteio. Estudantes em outras posições não são selecionados por essa regra. Portanto, a estratégia não constitui amostragem aleatória simples nem assegura representatividade.

Na estratégia I, frequentar o ginásio durante competições de basquetebol pode estar associado a características relacionadas à altura. Na II, medir todos os estudantes de engenharia cobre esse grupo, mas deixa os demais cursos fora da seleção. Aumentar o número de observações não corrige, por si só, esses problemas de cobertura e seleção.

A resposta correta é: A estratégia III é a mais adequada entre as propostas, pois evita restringir a seleção ao ginásio ou à engenharia. A escolha do primeiro nome de cada página não garante representatividade nem aleatoriedade.

Questão 3

Correto

Atingiu 0,50 de 0,50

Q3 (ARAUJO, 2013 p. 10) - Classificação de variáveis

Considere as seguintes variáveis observadas em um estudo com estudantes:

`idade`, `número de anos completos de estudo`, `sexo`, `nota em Métodos Quantitativos`, `tempo gasto diariamente no estudo`, `distância de casa à instituição`, `local de estudo` e `número de irmãos`.

A idade é registrada como tempo de vida decorrido, sem arredondamento para anos inteiros. Tempo de estudo e distância são medidos com precisão decimal. A nota é uma pontuação numérica, e os anos de estudo correspondem ao número de anos completos, não à série escolar.

Com base na classificação estatística dessas variáveis, analise as afirmativas a seguir.

I. `sexo` e `local de estudo` são variáveis qualitativas nominais.

II. `idade`, `tempo gasto diariamente no estudo` e `distância de casa à instituição` são variáveis quantitativas discretas.

III. `número de anos completos de estudo` e `número de irmãos` podem ser tratados como variáveis quantitativas discretas.

IV. `nota em Métodos Quantitativos` é uma variável qualitativa nominal, pois pode ser associada a categorias de desempenho.

V. Todas as variáveis listadas são quantitativas, pois podem receber representação numérica.

Está correto o que se afirma em:

Validação no Colab

Dispensada. Questão conceitual.

- A. I e II, apenas.
- B. II, III e IV, apenas.
- C. I e III, apenas. ✓ Correta. As afirmativas I e III estão corretas.
- D. III e V, apenas.
- E. I, III e V.

Alternativa correta.

Esta questão exige classificar variáveis segundo sua natureza. Variáveis qualitativas descrevem atributos ou categorias; variáveis quantitativas descrevem contagens ou medições numéricas. Entre as quantitativas, as discretas assumem valores contáveis, como número de irmãos, enquanto as contínuas resultam de mensuração, como tempo, distância e idade. A classificação correta da variável é decisiva para escolher tabelas, gráficos e medidas-resumo adequadas.

Neste enunciado, anos completos de estudo e número de irmãos são contagens discretas. Idade como tempo de vida, tempo de estudo e distância são grandezas contínuas, ainda que registradas com precisão finita. A nota é quantitativa, não uma categoria nominal. A codificação numérica de categorias não muda sua natureza qualitativa.

A resposta correta é: I e III, apenas.

Questão 4

Correto

Atingiu 1,00 de 1,00

Q4 (NAVIDI, 2024 p. 24) - Alteração de um valor extremo

O setor de recursos humanos revisa os salários de uma divisão com dez funcionários. Por erro de digitação, o maior salário, de US$ 100.000, foi registrado como US$ 1.000.000. Os demais salários permaneceram inalterados.

Dados: q4.csv. A coluna `salario` contém dez valores individuais simulados, em dólares, antes do erro.

Calcule a média, a mediana e o desvio-padrão amostral antes e depois dessa alteração. Qual afirmação interpreta corretamente seu efeito?

Validação no Colab

Apresente o código e as saídas da média, da mediana e do desvio-padrão amostral antes e depois da alteração. Justifique a alternativa escolhida. A alternativa correta sem validação adequada no notebook recebe zero neste item.

A. A média passa de US$ 70.000 para US$ 160.000, a mediana passa de US$ 55.000 para US$ 145.000 e o desvio-padrão aumenta. O acréscimo médio de US$ 90.000 desloca também a posição central dos salários.

B. A média passa de US$ 70.000 para US$ 160.000, a mediana permanece em US$ 55.000 e o desvio-padrão aumenta. O maior salário se afasta dos demais, mas as duas observações centrais permanecem inalteradas. ✓ relaciona corretamente a média à soma dos salários, a mediana às posições centrais e o aumento do desvio-padrão ao maior afastamento do extremo.

C. A média passa de US$ 70.000 para US$ 970.000, a mediana permanece em US$ 55.000 e o desvio-padrão aumenta. O acréscimo de US$ 900.000 no maior salário é incorporado integralmente à média da divisão.

D. A média passa de US$ 70.000 para US$ 160.000, a mediana permanece em US$ 55.000 e o desvio-padrão permanece em US$ 20.000. Alterar somente o maior salário não modifica a dispersão dos dez registros.

E. A média permanece em US$ 70.000, a mediana permanece em US$ 55.000 e o desvio-padrão aumenta. Como nove dos dez salários não mudaram, a influência do registro alterado se restringe à medida de dispersão.

Alternativa correta.

A alternativa B está correta. O erro acrescenta US$ 900.000 à soma dos dez salários, elevando a média em US$ 90.000, de US$ 70.000 para US$ 160.000. A mediana permanece em US$ 55.000 porque as observações nas posições 5 e 6 da lista ordenada não mudam.

O desvio-padrão amostral aumenta de US$ 20.000 para aproximadamente US$ 295.634,91. O maior salário torna-se muito mais distante dos demais, aumentando a dispersão. Manter nove registros inalterados não impede que uma única alteração afete fortemente a média e o desvio-padrão.

Neste caso, a mediana resiste ao aumento do valor extremo porque ele continua na última posição. Isso não significa que a mediana permaneça igual diante de qualquer alteração em um conjunto de dados.

Envie `q4.csv` desta prova para a pasta de trabalho do Colab e execute o código. O filtro identifica o único salário de 100.000 e modifica apenas esse registro. `std(ddof=1)` calcula o desvio-padrão amostral. Para repetir a comparação, execute novamente a célula completa, incluindo a leitura do CSV.

```
import pandas as pd

df = pd.read_csv("q4.csv")

print("Antes da alteração:")
print("Média:", round(df["salario"].mean(), 2))
print("Mediana:", round(df["salario"].median(), 2))
print("Desvio-padrão amostral:", round(df["salario"].std(ddof=1), 2))

df.loc[df["salario"] == 100000, "salario"] = 1000000

print("Após a alteração:")
print("Média:", round(df["salario"].mean(), 2))
print("Mediana:", round(df["salario"].median(), 2))
print("Desvio-padrão amostral:", round(df["salario"].std(ddof=1), 2))
```

Saída esperada:

```
Antes da alteração:
Média: 70000.0
Mediana: 55000.0
Desvio-padrão amostral: 20000.0
Após a alteração:
Média: 160000.0
Mediana: 55000.0
Desvio-padrão amostral: 295634.91
```

A resposta correta é: A média passa de US$ 70.000 para US$ 160.000, a mediana permanece em US$ 55.000 e o desvio-padrão aumenta. O maior salário se afasta dos demais, mas as duas observações centrais permanecem inalteradas.

Comentário:
Questão validada! Calcula as três medidas antes e depois da alteração e explica as mudanças na média e na dispersão, bem como a manutenção da mediana (Q4, células 7–12).

Questão 5

Parcialmente correto

Atingiu 0,75 de 1,50

Q5 (MORETTIN; BUSSAB, 2010 pp. 56–57) - Distribuição das vendas semanais

Uma distribuidora deseja analisar as vendas semanais de vendedores de gêneros alimentícios, em salários mínimos, para discutir metas. O arquivo fornecido contém 220 valores individuais simulados.

Foi proposto apresentar a faixa mais frequente como o resultado da maioria dos vendedores e descrever a equipe apenas pela média.

Dados: q5.csv. A coluna `vendas` contém os valores individuais.

Considere as classes [30, 35), [35, 40), [40, 45), [45, 50), [50, 55), [55, 60), [60, 65) e [65, 70], com o limite superior incluído apenas na última classe. Construa a tabela de frequências e o histograma.

Estime a média e o desvio-padrão amostral dos dados agrupados. Qual afirmação deve orientar a apresentação dos resultados?

Validação no Colab

Apresente o código, a tabela de frequências, o histograma com eixos identificados e as estimativas agrupadas da média e do desvio-padrão amostral. Justifique a alternativa escolhida. A tabela e o histograma integram a validação obrigatória deste item. A alternativa correta sem validação adequada no notebook recebe zero neste item.

- A. Apresentar a faixa de 50 a menos de 55 como o resultado da maioria da equipe, pois ela concentra a maior frequência. Usar a média de 51,09 e o desvio-padrão de 8,25 para descrever as vendas.
  ✕ a maior frequência corresponde a 31,82% dos vendedores. A classe modal não reúne a maioria absoluta da equipe.
- B. Apresentar a faixa de 45 a menos de 55 como o resultado de 54,55% da equipe. Usar a média de 51,09 e o desvio-padrão de 8,25 para descrever o nível e a dispersão das vendas.
- C. Apresentar a faixa de 50 a menos de 55 como responsável por 31,82% do valor total vendido, conforme sua frequência. Usar a média de 51,09 e o desvio-padrão de 8,25 para descrever as vendas.
- D. Apresentar a faixa de 45 a menos de 55 como o resultado de 54,55% da equipe, com média de 51,09. Interpretar o desvio-padrão de 8,25 como a distância máxima das vendas individuais em relação à média.
- E. Apresentar a faixa de 50 a menos de 55 como referência suficiente para descrever a equipe, pois contém a média de 51,09. Interpretar essa coincidência como evidência de simetria, com desvio-padrão de 8,25.

A resposta não atende integralmente ao item.

A alternativa B está correta. A classe modal, de 50 a menos de 55 salários mínimos, contém 70 dos 220 vendedores, ou 31,82%. Ser a classe mais frequente não significa reunir a maioria absoluta. As duas classes de 45 a menos de 55 somam 120 vendedores, ou 54,55% da equipe, justificando a faixa indicada na afirmação.

A média estimada de 51,09 salários mínimos descreve o nível médio, enquanto o desvio-padrão amostral estimado de 8,25 salários mínimos informa a dispersão. Essa medida não representa a distância máxima à média. A média pertencer à classe modal também não comprova simetria nem torna essa classe suficiente para descrever toda a distribuição.

O percentual de 31,82% refere-se ao número de vendedores da classe modal, não à participação no valor total vendido. O histograma e as medidas devem ser considerados em conjunto na discussão das metas. Descrever o desempenho observado não basta para definir uma meta adequada.

Envie `q5.csv` desta prova para a pasta de trabalho do Colab e execute o código. `np.histogram` calcula as frequências nas classes definidas, incluindo o limite direito apenas na última. O histograma usa os mesmos limites. As medidas agrupadas usam pontos médios e frequências, com divisor $n - 1$ na variância. Calcular as medidas diretamente na coluna `vendas` pode produzir valores diferentes das estimativas agrupadas solicitadas.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv("q5.csv")
lim = np.arange(30, 71, 5)
freq, _ = np.histogram(df["vendas"], bins=lim)
tab = pd.DataFrame({"li": lim[:-1], "ls": lim[1:], "freq": freq})
print("Tabela de frequências:")
print(tab)

tab["pm"] = (tab["li"] + tab["ls"]) / 2
n = tab["freq"].sum()
media = np.average(tab["pm"], weights=tab["freq"])
dp = np.sqrt(np.sum(tab["freq"] * (tab["pm"] - media) ** 2) / (n - 1))
modal = tab[tab["freq"] == tab["freq"].max()]
faixa = tab[(tab["li"] >= 45) & (tab["ls"] <= 55)]

print("Média agrupada estimada:", round(media, 2))
print("Desvio-padrão amostral agrupado estimado:", round(dp, 2))
print("Classe modal:")
print(modal[["li", "ls", "freq"]])
print("Vendedores na classe modal (%):", round(100 * modal["freq"].sum() / n, 2))
print("Vendedores de 45 a menos de 55:", faixa["freq"].sum())
print("Vendedores de 45 a menos de 55 (%):", round(100 * faixa["freq"].sum() / n, 2))

plt.hist(df["vendas"], bins=lim, edgecolor="black")
plt.xticks(lim)
plt.xlabel("Vendas semanais (salários mínimos)")
plt.ylabel("Número de vendedores")
plt.title("Vendas semanais - dados simulados")
plt.show()
```

Saída numérica esperada, acompanhada do histograma:

```
Tabela de frequências:
   li  ls  freq
0  30  35    12
1  35  40    10
2  40  45    18
3  45  50    50
4  50  55    70
5  55  60    30
6  60  65    18
7  65  70    12
Média agrupada estimada: 51.09
Desvio-padrão amostral agrupado estimado: 8.25
Classe modal:
   li  ls  freq
4  50  55    70
Vendedores na classe modal (%): 31.82
Vendedores de 45 a menos de 55: 120
Vendedores de 45 a menos de 55 (%): 54.55
```

O histograma apresenta oito barras contíguas. A mais alta corresponde à classe de 50 a menos de 55, com 70 vendedores. A classe anterior contém 50 vendedores. Essas duas barras sustentam a conclusão de maioria absoluta no intervalo conjunto.

A resposta correta é: Apresentar a faixa de 45 a menos de 55 como o resultado de 54,55% da equipe. Usar a média de 51,09 e o desvio-padrão de 8,25 para descrever o nível e a dispersão das vendas.

Comentário:

Questão parcialmente validada! Usa as classes corretas no histograma, mas a tabela conta valores individuais e as medidas não são agrupadas. Falta identificar o eixo horizontal (Q5, células 14–21). A justificativa está ausente, sem desconto por essa ausência.

Questão 6

Correto

Atingiu 1,00 de 1,00

Q6 (NAVIDI, 2024 p. 42) - Média, mediana e forma da distribuição

Uma equipe analisa um conjunto de 21 observações para descrever a forma de sua distribuição. Um integrante propõe identificar a direção da assimetria comparando apenas a média e a mediana.

Dados: q6.csv. A coluna `valor` contém as observações.

Em geral, distribuições com assimetria à esquerda apresentam média menor que a mediana, enquanto distribuições com assimetria à direita apresentam média maior que a mediana. Essa relação, entretanto, não é universal.

Calcule a média e a mediana e construa o histograma com as classes $[-0{,}5; 0{,}5)$, $[0{,}5; 1{,}5)$, $[1{,}5; 2{,}5)$ e $[2{,}5; 3{,}5]$. O limite superior é incluído apenas na última classe. Qual afirmação interpreta corretamente os resultados?

Validação no Colab

Apresente o código, a média, a mediana e o histograma com as classes definidas e os eixos identificados. Justifique a alternativa escolhida relacionando as medidas à forma do gráfico. O histograma integra a validação obrigatória. A alternativa correta sem validação adequada no notebook recebe zero neste item.

- A. A média é 0,76 e a mediana é 1,00. Como a média é menor, a distribuição apresenta assimetria à esquerda, e essa relação numérica determina a direção da cauda observada no histograma.
- B. A média é 0,76 e a mediana é 1,00. O histograma apresenta cauda à direita, mostrando que a comparação dessas medidas, isoladamente, não determina a direção da assimetria neste conjunto. ✓ combina os cálculos corretos com a leitura da cauda à direita e reconhece o limite da comparação isolada entre média e mediana.
- C. A média é 1,00 e a mediana é 0,76. O histograma apresenta cauda à direita, confirmando que a média supera a mediana e que essa relação numérica descreve a assimetria neste conjunto.
- D. A média é 0,76 e a mediana é 1,00. O histograma apresenta cauda à esquerda, pois a maior concentração de observações nos menores valores determina o lado para o qual a cauda se estende.
- E. A média é 0,76 e a mediana é 1,00. O histograma apresenta distribuição simétrica, pois a diferença inferior a uma unidade entre essas medidas indica equilíbrio das frequências nos dois lados.

Alternativa correta.

A alternativa B está correta. A soma dos 21 valores é 16, de modo que a média é $16/21 \approx 0{,}76$. Na lista ordenada, a 11ª observação é 1, portanto a mediana é 1,00.

As frequências dos valores 0, 1, 2 e 3 são, respectivamente, 10, 7, 3 e 1. O histograma concentra observações nos menores valores e se prolonga para a direita com frequências decrescentes. Sua cauda está à direita, embora a média seja menor que a mediana.

A relação usual entre média, mediana e assimetria não é uma regra universal. Neste conjunto, a comparação isolada das duas medidas sugeriria a direção oposta à forma observada. A direção da cauda deve ser avaliada no gráfico, distinguindo-a do lado com maior concentração de observações. A proximidade numérica entre média e mediana também não comprova simetria.

Envie `q6.csv` desta prova para a pasta de trabalho do Colab e execute o código. As medidas são calculadas diretamente nas observações. Os limites do histograma colocam cada valor inteiro no centro de sua classe.

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("q6.csv")

print("Média:", round(df["valor"].mean(), 2))
print("Mediana:", round(df["valor"].median(), 2))

lim = [-0.5, 0.5, 1.5, 2.5, 3.5]
plt.hist(df["valor"], bins=lim, edgecolor="black")
plt.xticks([0, 1, 2, 3])
plt.xlabel("Valor")
plt.ylabel("Frequência")
plt.title("Distribuição das 21 observações")
plt.show()
```

Saída esperada, acompanhada do histograma:

```
Média: 0.76
Mediana: 1.0
```

O gráfico apresenta quatro barras contíguas, com alturas 10, 7, 3 e 1, nessa ordem. A barra mais alta está à esquerda, enquanto a cauda se estende para a direita.

A resposta correta é: A média é 0,76 e a mediana é 1,00. O histograma apresenta cauda à direita, mostrando que a comparação dessas medidas, isoladamente, não determina a direção da assimetria neste conjunto.

Comentário:

Questão validada! Calcula as medidas e usa as classes corretas, mas não identifica o eixo horizontal (Q6, células 23–27). A justificativa está ausente, sem desconto por essa ausência. A ausência de identificação dos eixos também não reduz a nota.

Questão 7

Incorreto

Atingiu 0,00 de 1,50

Q7 (MORETTIN; BUSSAB, 2010 p. 64) - Cercas de Tukey e investimento básico

Um órgão estadual analisa o investimento em educação por habitante de dez cidades, expresso em valores codificados. Para este levantamento, define o investimento básico como a média após uma única exclusão dos valores sinalizados pelas cercas de Tukey, calculadas sobre o conjunto inicial.

Dados: q7.csv. As colunas `cidade` e `inv` identificam a cidade e seu investimento.

Construa o boxplot e aplique a cerca de Tukey, conforme abordado nas aulas. Qual afirmação apresenta o investimento básico e interpreta corretamente o procedimento?

Validação no Colab

Apresente o código, o boxplot do conjunto inicial, os quartis, o IQR, as cercas de Tukey, a cidade sinalizada e a média após a exclusão. Justifique a alternativa escolhida. O gráfico integra a validação obrigatória. A alternativa correta sem validação adequada no notebook recebe zero neste item.

- A. O investimento básico é 15,80, mantendo as dez cidades. O valor 7 deve permanecer porque sua distância à média não altera a posição central, tornando desnecessária a exclusão prevista no critério.
- B. O investimento básico é 15,10, após excluir o valor 7. A soma dos investimentos restantes deve ser dividida por dez, pois esse era o número de cidades no levantamento usado para calcular as cercas.
- C. O investimento básico é 15,33, após excluir o valor 20. O maior investimento deve ser retirado porque os valores acima da média caracterizam a cauda superior e são sinalizados pelo critério de Tukey.
- D. O investimento básico é 16,78, após excluir o valor 7. Esse valor está abaixo da cerca inferior, e a média é recalculada com nove cidades, conforme a definição adotada para este levantamento.
- E. O investimento básico é 16,78, após excluir o valor 7. Estar abaixo da cerca inferior comprova erro no registro, tornando sua retirada necessária em qualquer análise dos investimentos dessas cidades.

Alternativa incorreta. Consulte a justificativa quando o feedback for liberado.

A alternativa D está correta. Os quartis são Q1 = 14,25 e Q3 = 18,75, com IQR = 4,50. As cercas de Tukey são 7,50 e 25,50. Apenas o investimento 7, da cidade D, está fora delas. O valor 20 está dentro das cercas.

A média inicial é 15,80. Após retirar o valor 7, a soma dos investimentos é 151 e restam nove cidades. O investimento básico é, portanto, $151/9 \approx 16,78$. Manter dez no denominador produziria 15,10 e equivaleria a substituir o valor excluído por zero.

A exclusão é uma regra específica deste exercício. A sinalização pelo boxplot não comprova erro de registro nem determina que o valor deva ser removido em outras análises. Em uma investigação real, sua origem e o objetivo da análise precisam ser considerados.

Envie `q7.csv` desta prova para a pasta de trabalho do Colab e execute o código. Os quartis usam a interpolação linear padrão do pandas, adotada nas aulas. Os filtros identificam valores fora das cercas e preservam aqueles que estão nos limites ou entre eles. As cercas são calculadas uma única vez, antes da exclusão.

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("q7.csv")

q1 = df["inv"].quantile(0.25)
q3 = df["inv"].quantile(0.75)
iqr = q3 - q1
li = q1 - 1.5 * iqr
ls = q3 + 1.5 * iqr
fora = df[(df["inv"] < li) | (df["inv"] > ls)]
dentro = df[(df["inv"] >= li) & (df["inv"] <= ls)]

print("Q1:", q1)
print("Q3:", q3)
print("IQR:", iqr)
print("Cerca inferior:", li)
print("Cerca superior:", ls)
print("Cidades sinalizadas:")
print(fora)
print("Média inicial:", round(df["inv"].mean(), 2))
print("Número de cidades restantes:", len(dentro))
print("Investimento básico:", round(dentro["inv"].mean(), 2))

plt.boxplot(df["inv"])
plt.xticks([1], ["Cidades"])
plt.ylabel("Investimento por habitante (valor codificado)")
plt.title("Investimentos antes da exclusão")
plt.show()
```

Saída esperada, acompanhada do boxplot:

```
Q1: 14.25
Q3: 18.75
IQR: 4.5
Cerca inferior: 7.5
Cerca superior: 25.5
Cidades sinalizadas:
  cidade  inv
3      D    7
Média inicial: 15.8
Número de cidades restantes: 9
Investimento básico: 16.78
```

O boxplot apresenta um ponto abaixo da haste inferior, correspondente ao investimento 7. O gráfico representa o conjunto inicial, permitindo verificar o valor retirado antes de interpretar a média final.

A resposta correta é: O investimento básico é 16,78, após excluir o valor 7. Esse valor está abaixo da cerca inferior, e a média é recalculada com nove cidades, conforme a definição adotada para este levantamento.

Comentário:

Questão não validada! Apenas importa e exibe os dados, sem realizar a análise solicitada (Q7, células 29–30). A justificativa está ausente, sem desconto por essa ausência.

Questão 8

Incorreto

Atingiu 0,00 de 1,50

Q8 (NAVIDI, 2024 p. 41) - Interpretação comparativa de boxplots

Uma equipe compara a quantidade de nitrato de econazol absorvida pela pele após a aplicação de uma pomada de marca e de uma genérica. Para a análise, dispõe de dados simulados de absorção, em $\mu g/cm^2$, que reproduzem aproximadamente as características dos boxplots apresentados por Navidi.

Dados: q8.csv. As colunas `marca` e `generico` contêm 41 observações de cada formulação. As linhas não representam pares de medições do mesmo indivíduo.

Construa os boxplots e calcule os quartis, os intervalos interquartis (IQR) e as cercas de Tukey. Qual afirmação interpreta corretamente os resultados?

Validação no Colab

Apresente o código, os boxplots com eixos identificados, os quartis, os IQRs, as cercas e os valores discrepantes. Justifique a alternativa escolhida. Os gráficos integram a validação obrigatória. A alternativa correta sem validação adequada no notebook recebe zero neste item.

- A. O genérico apresenta mediana maior, e as dispersões dos 50% centrais são semelhantes. Há valores discrepantes superiores na marca e um inferior no genérico, sinalizados pelas cercas de Tukey.
- B. A marca apresenta maior amplitude total e, portanto, maior dispersão dos 50% centrais. Há valores discrepantes superiores na marca e um inferior no genérico, sinalizados pelas cercas de Tukey.
- C. O genérico apresenta mediana maior e caixa mais longa, contendo maior proporção das observações. Há valores discrepantes superiores na marca e um inferior no genérico, sinalizados por Tukey.
- D. O genérico apresenta mediana maior, e as dispersões dos 50% centrais são semelhantes. Cerca de metade das observações de cada formulação é discrepante, pois se encontra fora da respectiva caixa.
- E. O genérico apresenta mediana maior, e as dispersões dos 50% centrais são semelhantes. Esses resultados demonstram sua superioridade terapêutica, pois a absorção mediana supera a da pomada de marca.

Alternativa incorreta. Consulte a justificativa quando o feedback for liberado.

A alternativa A está correta. A mediana da marca é 2,60 e a do genérico é 2,85 $\mu g/cm^2$. Os quartis da marca são 2,10 e 3,10, com IQR de 1,00. Os do genérico são 2,30 e 3,35, com IQR de 1,05. Assim, as dispersões dos 50% centrais são semelhantes, com IQR ligeiramente maior no genérico.

As cercas da marca são 0,60 e 4,60. Os valores 5,00, 5,25 e 5,55 ultrapassam a cerca superior. As cercas do genérico são 0,725 e 4,925, e somente 0,60 fica abaixo da cerca inferior. Os bigodes terminam nos valores observados dentro das cercas: 1,10 e 4,05 na marca, 1,40 e 4,00 no genérico.

A marca tem maior amplitude total, mas isso não implica maior IQR. A amplitude usa os extremos, enquanto o IQR descreve a dispersão da metade central. Uma caixa mais longa também não representa maior proporção de observações. Cada caixa delimita aproximadamente os 50% centrais.

Estar fora da caixa não basta para ser discrepante. A sinalização exige ultrapassar as cercas de Tukey. A comparação da absorção nesses dados simulados tampouco demonstra superioridade terapêutica.

Envie `q8.csv` desta prova para a pasta de trabalho do Colab e execute o código. Os quartis usam a interpolação linear padrão do pandas, adotada nas aulas. Os filtros selecionam observações estritamente fora das cercas. Os boxplots usam o mesmo critério.

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("q8.csv")
q1 = df.quantile(0.25)
q3 = df.quantile(0.75)
iqr = q3 - q1
li = q1 - 1.5 * iqr
ls = q3 + 1.5 * iqr

print("Quartis e medianas:")
print(df.quantile([0.25, 0.50, 0.75]))
print("IQR:")
print(iqr.round(3))
print("Cercas inferiores:")
print(li.round(3))
print("Cercas superiores:")
print(ls.round(3))
print("Discrepantes da marca:")
print(df["marca"][(df["marca"] < li["marca"]) | (df["marca"] > ls["marca"])].sort_values())
print("Discrepantes do genérico:")
print(df["generico"][(df["generico"] < li["generico"]) | (df["generico"] > ls["generico"])].sort_values())

plt.boxplot([df["marca"], df["generico"]])
plt.xticks([1, 2], ["Marca", "Genérico"])
plt.ylabel("Absorção (µg/cm²)")
plt.title("Absorção – dados simulados")
plt.show()
```

Saída esperada, acompanhada dos boxplots:

```
Quartis e medianas:
      marca  generico
0.25    2.1      2.30
0.50    2.6      2.85
0.75    3.1      3.35
IQR:
marca       1.00
generico    1.05
dtype: float64
Cercas inferiores:
marca       0.600
generico    0.725
dtype: float64
Cercas superiores:
marca       4.600
generico    4.925
dtype: float64
Discrepantes da marca:
0     5.00
32    5.25
12    5.55
Name: marca, dtype: float64
Discrepantes do genérico:
13    0.6
Name: generico, dtype: float64
```

O gráfico apresenta caixas de comprimentos próximos, mediana maior no genérico, três pontos acima do bigode superior da marca e um abaixo do bigode inferior do genérico.

A resposta correta é: O genérico apresenta mediana maior, e as dispersões dos 50% centrais são semelhantes. Há valores discrepantes superiores na marca e um inferior no genérico, sinalizados pelas cercas de Tukey.

Comentário:

Questão não validada! Não apresenta resolução (Q8, células 31–33). A justificativa está ausente, sem desconto por essa ausência.

Questão 9

Incorreto

Atingiu 0,00 de 1,50

Q9 (ARAÚJO, 2013; banco, p. 13) - Escolaridade e comparação entre grupos

O arquivo q9.csv contém dados simulados de uma amostra de funcionários, com informações sobre sexo e escolaridade. Cada linha representa um funcionário. A coluna `sexo` identifica o sexo e a coluna `escolaridade` indica primeiro grau, segundo grau ou nível superior. Cada funcionário pertence a apenas um desses níveis.

Construa a tabela de contingência com os totais e calcule os percentuais de funcionários com apenas o primeiro grau em relação ao total da amostra, dentro de cada sexo e entre os funcionários desse nível de instrução. Qual afirmação está correta?

Validação no Colab

Apresente o código, a tabela de contingência com totais e os percentuais conjuntos, dentro de cada sexo e de composição por sexo entre os funcionários com primeiro grau. Justifique a alternativa escolhida. A alternativa correta sem validação adequada no notebook recebe zero neste item.

- A. Há 135 mulheres e 65 homens com apenas o primeiro grau. Os percentuais de 27% e 13%, respectivamente, mostram que essa escolaridade é proporcionalmente mais frequente dentro do grupo feminino.
- B. Há 135 mulheres e 65 homens com apenas o primeiro grau. Os percentuais de 67,5% e 32,5%, respectivamente, representam a presença dessa escolaridade dentro de cada sexo.
- C. Há 135 mulheres e 65 homens com apenas o primeiro grau, correspondendo a 36% das mulheres e 52% dos homens. Esses percentuais descrevem também todos os funcionários da empresa.
- D. Há 135 mulheres e 65 homens com apenas o primeiro grau, correspondendo a 36% das mulheres e 52% dos homens. A quantidade é maior entre as mulheres, mas a proporção é maior entre os homens.
- E. Há 135 mulheres e 65 homens com apenas o primeiro grau, correspondendo a 52% das mulheres e 36% dos homens. A quantidade e a proporção dessa escolaridade são maiores entre as mulheres.

Alternativa incorreta. Consulte a justificativa quando o feedback for liberado.

A alternativa D está correta. A amostra contém 375 mulheres e 125 homens. Há 200 funcionários com apenas o primeiro grau: 65 homens e 135 mulheres. Assim, essa escolaridade corresponde a $135/375 = 36\%$ das mulheres e a $65/125 = 52\%$ dos homens. A maior quantidade de mulheres não implica maior proporção dentro do grupo feminino, pois os grupos têm tamanhos diferentes.

Dividir por 500 produz percentuais conjuntos: 27% da amostra são mulheres com apenas o primeiro grau, e 13% são homens com essa escolaridade. Dividir por 200 responde a outra pergunta: entre os funcionários com apenas o primeiro grau, 67,5% são mulheres e 32,5% são homens. Para comparar a frequência proporcional dessa escolaridade dentro de cada sexo, o denominador deve ser o total do respectivo sexo. Sem informações sobre a seleção da amostra, não se pode atribuir os mesmos percentuais a todos os funcionários da empresa.

Envie `q9.csv` para a pasta de trabalho do Colab. Cada linha é um registro individual. `pd.crosstab` conta os funcionários em cada combinação de sexo e escolaridade. Os totais permitem calcular os três tipos de percentual, alterando o denominador.

```
import pandas as pd

df = pd.read_csv("q9.csv")
tab = pd.crosstab(df["sexo"], df["escolaridade"], margins=True, margins_name="Total")

print(tab)
for sexo in ["Feminino", "Masculino"]:
    n = tab.loc[sexo, "primeiro"]
    print(sexo)
    print("Primeiro grau em relação à amostra (%):", 100 * n / tab.loc["Total", "Total"])
    print("Primeiro grau dentro do sexo (%):", 100 * n / tab.loc[sexo, "Total"])
    print("Sexo entre os funcionários com primeiro grau (%):", 100 * n / tab.loc["Total", "primeiro"])
```

Saída esperada:

```
escolaridade  primeiro  segundo  superior  Total
sexo
Feminino           135      233         7    375
Masculino           65       42        18    125
Total              200      275        25    500
Feminino
Primeiro grau em relação à amostra (%): 27.0
Primeiro grau dentro do sexo (%): 36.0
Sexo entre os funcionários com primeiro grau (%): 67.5
Masculino
Primeiro grau em relação à amostra (%): 13.0
Primeiro grau dentro do sexo (%): 52.0
Sexo entre os funcionários com primeiro grau (%): 32.5
```

A tabela reúne 500 registros. Os percentuais dentro de cada sexo são 36% e 52%. A comparação entre quantidades e proporções confirma a alternativa D.

A resposta correta é: Há 135 mulheres e 65 homens com apenas o primeiro grau, correspondendo a 36% das mulheres e 52% dos homens. A quantidade é maior entre as mulheres, mas a proporção é maior entre os homens.

Comentário:

Questão não validada! Não apresenta resolução (Q9, células 34–36). A justificativa está ausente, sem desconto por essa ausência.

Questão 10

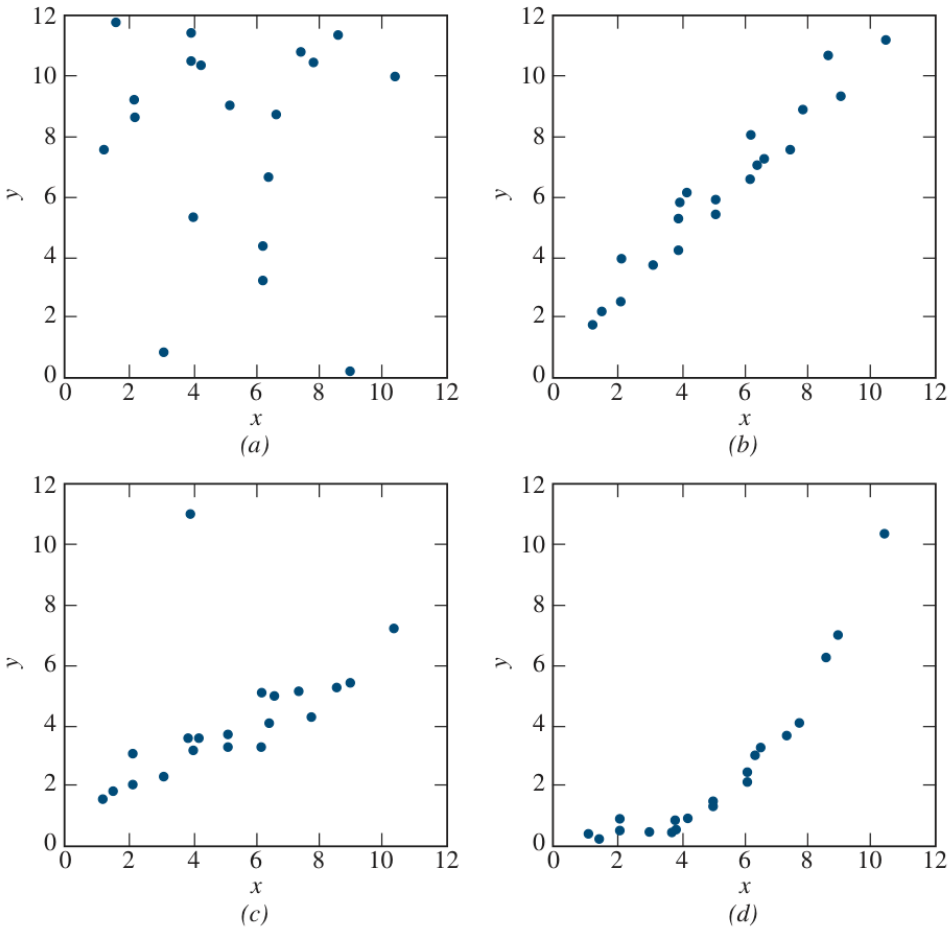
Correto

Atingiu 0,50 de 0,50

Q10 (NAVIDI, 2024 p. 42) - Leitura de gráficos de dispersão

Um **gráfico de dispersão** mostra pares de valores `(x, y)` para duas variáveis medidas conjuntamente. Seu uso aqui é apenas **descritivo e visual**, sem cálculo de correlação formal.

Observe os quatro diagramas a seguir.



Qual alternativa descreve corretamente um dos padrões mostrados?

Validação no Colab

Dispensada. Questão conceitual.

A. O gráfico `(a)` mostra tendência linear positiva, sem valores discrepantes aparentes.

B. O gráfico `(b)` mostra tendência positiva, mas com dispersão suficiente para impedir qualquer associação visual entre as variáveis.

C. O gráfico `(c)` mostra tendência aproximadamente linear positiva, com um ponto mais afastado do padrão principal. ✓ Correta. Há padrão positivo com um ponto afastado da nuvem principal.

D. O gráfico `(d)` mostra tendência crescente, porém predominantemente linear, sem indicação de curvatura.

E. O gráfico `(c)` não sugere associação visual, pois um ponto discrepante invalida a análise do padrão geral.

Alternativa correta.

Nesta questão, o objetivo é ler padrões visuais em gráficos de dispersão sem recorrer a medida formal de associação. Um conjunto pode sugerir tendência linear, tendência curvilínea, ausência de padrão ou influência de ponto afastado. No gráfico `(c)`, há tendência positiva aproximadamente linear, mas um ponto se destaca do padrão principal, o que exige leitura qualitativa cuidadosa.

A resposta correta é: O gráfico `(c)` mostra tendência aproximadamente linear positiva, com um ponto mais afastado do padrão principa

Questão 11

Completo

Não avaliada

Entrega do notebook

Anexe **um arquivo .ipynb** com a validação das questões 4, 5, 6, 7, 8 e 9. Identifique nome, matrícula e turma no cabeçalho. Este campo não acrescenta pontos à prova.

1. No Google Colab, confira se os códigos foram executados e se os resultados, gráficos e justificativas estão visíveis. Preserve as saídas.
2. Use **Arquivo → Fazer download → Fazer download do .ipynb** (em inglês, **File → Download → Download .ipynb**). Em algumas interfaces, a opção aparece diretamente no menu Arquivo.
3. Localize o arquivo baixado e renomeie-o como `AT1_matricula.ipynb`, substituindo `matricula` pelo seu número de matrícula.
4. Use o campo de anexos abaixo para selecionar o arquivo. Confirme que o nome aparece no campo e que o envio terminou.
5. Revise as alternativas e use **Finalizar tentativa** e **Enviar tudo e terminar**, conforme os botões apresentados pelo AVA.

O arquivo deve ser o notebook executado, não um PDF, um arquivo .py, um ZIP ou um link de compartilhamento. Se o download ou anexo falhar, avise o docente antes do término do prazo.

AT1_adriel.ipynb

O notebook será conferido pelo docente. A validação dos cálculos e gráficos determina a manutenção da nota nos itens que exigem Colab.

◄ Dúvidas e esclarecimentos

Seguir para...

AT1 - 2a chamada ►